Reducción de dimensionalidad: PCA frente a SVD

Cómo pasar de muchas variables a pocas sin perder lo esencial, y por qué es la base de los sistemas de recomendación

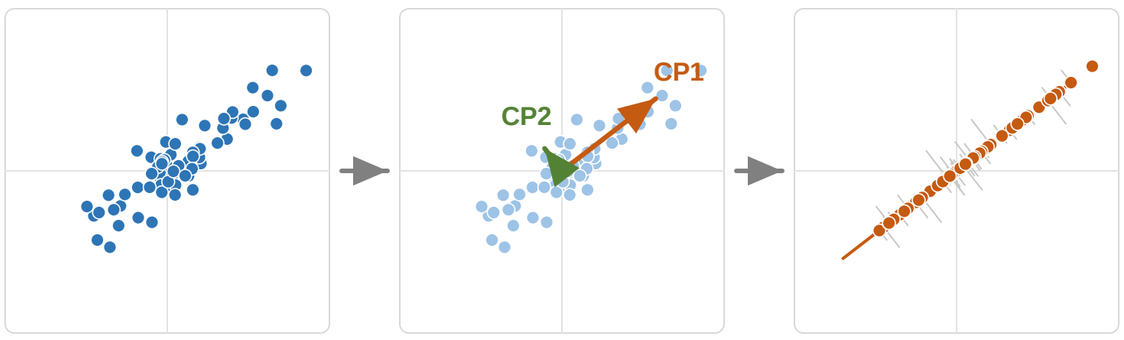
Ricardo Acuña · Juan Aquino · Camilo Soto

El problema. Una matriz de utilidad tiene millones de usuarios y cientos de miles de ítems, casi todas las celdas vacías.
La idea. Los gustos se explican con pocos **factores ocultos**. Reducir la dimensión es encontrar esos factores y describir a cada usuario e ítem con k números.

PCA Análisis de componentes principales

Crea variables nuevas, combinaciones lineales de las originales, que maximizan la varianza.

1 De la nube 2D a una sola dimensión



Nube original · Eje de máxima varianza · Proyección sobre CP1

Lectura: CP1 conserva el 95 % de la varianza; las líneas grises son el error que PCA minimiza.

2 Las fórmulas, en lenguaje simple

$X_c = X - \text{media}$	Centrar: mover el origen al centro de la nube.
$C = X_c^T X_c / (n - 1)$	Covarianza: cómo varían y covarían las variables.
$C\,w = \lambda\,w$	w: direcciones nuevas; λ: la varianza en cada una.
$Z = X_c\,W_k$	Proyectar: coordenadas en las k primeras componentes.
$\lambda_i / \Sigma\,\lambda_j$	Varianza explicada: cuánta información guarda cada una.

3 Varianza explicada: scree plot de los dígitos (64 píxeles)



Regla práctica: elegir k donde la acumulada supera el 90 % o donde se forma el codo.

4 Ventajas

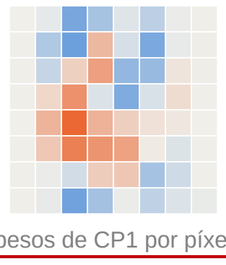
Menos ruido
El ruido se reparte en todas las direcciones y la señal en las primeras: el error baja de 16,0 a 7,2 en dígitos.

Visualización
Dos o tres componentes bastan para dibujar datos de cientos de dimensiones en un plano.

Velocidad
Con 21 de 64 variables un kNN mantiene la exactitud (0,98) y responde unas tres veces más rápido.

Casos de uso: preprocesado de modelos, compresión, eigenfaces, genómica, índices compuestos.

5 Limitación clave: se pierde la interpretabilidad



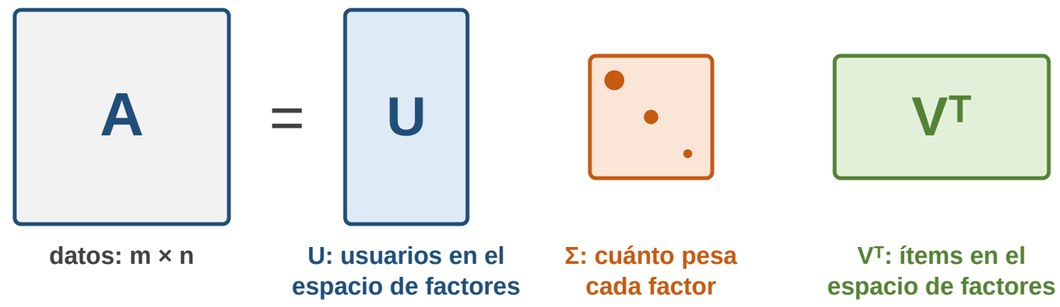
pesos de CP1 por píxel

Cada componente mezcla todas las variables con pesos positivos (naranja) y negativos (azul). Decir que un dígito tiene CP1 alta no responde a una pregunta simple sobre sus píxeles.
Además: solo capta estructura lineal y es sensible a la escala y a valores atípicos.

SVD Descomposición en valores singulares

El fundamento algebraico de PCA y de otras técnicas: factoriza cualquier matriz.

1 La ecuación $A = U \cdot \Sigma \cdot V^T$



datos: m × n · U: usuarios en el espacio de factores · Σ: cuánto pesa cada factor · V^T: ítems en el espacio de factores

Sin demostración: toda matriz, aunque sea rectangular o dispersa, es una rotación (V^T), un estiramiento por los valores singulares $\sigma_1 \geq \sigma_2 \geq \ldots \geq 0$ (Σ) y otra rotación (U).

$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \ldots$ k capas dan la mejor aproximación de rango k.

2 Una imagen es una matriz: truncar es comprimir



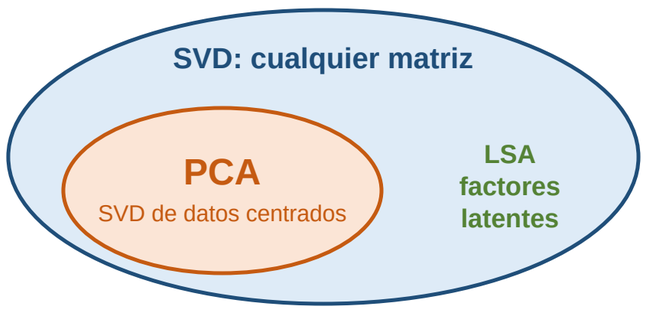
Original
16 384 números

k = 10
2 570 números · 99,08 % de energía

k = 50
12 850 números · 99,97 % de energía

Costo: k (m + n + 1) números frente a m · n. En 512 × 512 píxeles, k = 50 ocupa el 20 %.

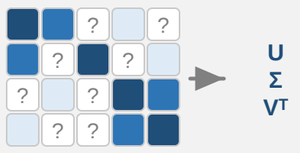
3 Relación con PCA



Si $X_c = U\,\Sigma\,V^T$ entonces:
$W = V$ (componentes)
$\lambda_i = \sigma_i^2 / (n - 1)$ (varianzas)
$Z = U\,\Sigma$ (coordenadas)
Ejemplo: σ = 6 y 2, λ = 36/4 = 9 y 4/4 = 1.

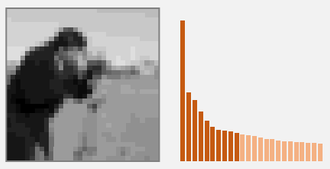
4 Tres aplicaciones

Recomendación



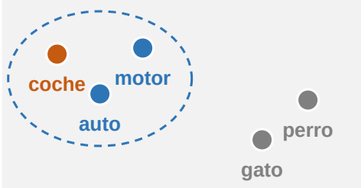
Matriz de utilidad ≈ U Σ V^T. Usuario y película quedan en k conceptos; la nota predicha es su producto. RMSE con k = 2: de 1,27 (media) a 0,43.

Compresión



Imágenes, señales y capas de redes neuronales se guardan con k capas. En 512 × 512, k = 10 ya reconoce la escena con el 4 % de los números.

Búsqueda semántica

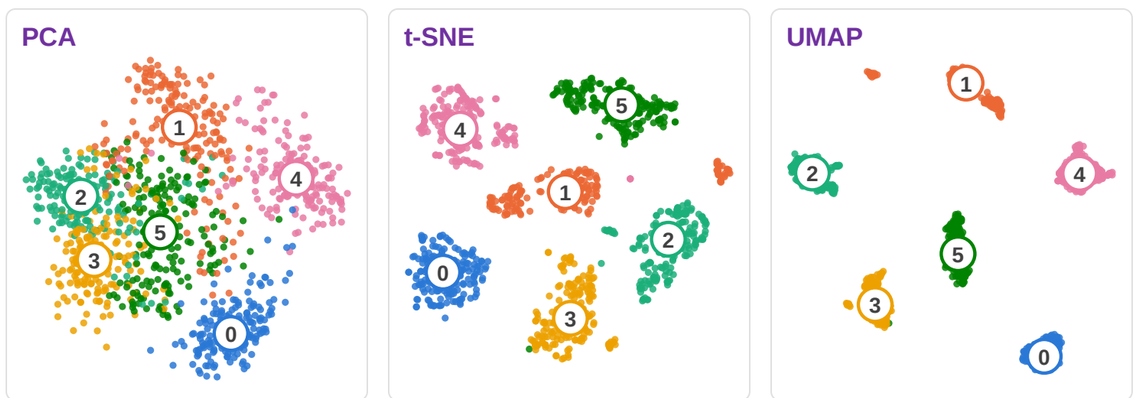


LSA aplica SVD a la matriz término documento. La consulta coche encuentra auto rojo corre carretera (coseno 0,88) sin compartir ninguna palabra.

PCA frente a SVD de un vistazo

	PCA	SVD
Entrada	Datos centrados	Cualquier matriz
Objetivo	Máxima varianza	Mejor aproximación de rango k
Cálculo	Autovectores de C	U, Σ y V de A
Matriz dispersa	No: centrar la llena	Sí, sin centrar
Salida	Componentes y varianzas	Factores de filas y columnas
Uso estrella	Preprocesado y ruido	Recomendación y LSA

Más allá de lo lineal: t-SNE y UMAP preservan vecindades



Dígitos del 0 al 5. PCA superpone grupos; t-SNE y UMAP los separan. Sirven para visualizar: el tamaño de los grupos y las distancias entre ellos no son métricos.

Material complementario: notebook con implementación desde cero, visualizador interactivo con d3 y documento .tex con el desarrollo matemático y ejemplos numéricos.

Referencias: Pearson (1901); Eckart y Young (1936); Deerwester y colaboradores (1990); Koren, Bell y Volinsky (2009); Shlens (2014); van der Maaten y Hinton (2008); McInnes, Healy y Melville (2018).